

◇ DATOS ◇ CÓDIGO ◇ MODELOS ◇ INFRAESTRUCTURA

Mejores Prácticas de MLOps

Llevar a producción sistemas de machine learning que sigan siendo confiables, reproducibles y mantenibles, mucho después de la demo.

Adaptado de un artículo de Yadidiah Kanaparthi

Usa ← → o Espacio para navegar_

CUESTIONARIO · MLFLOW

PREGUNTA 1 DE 10

En MLflow, ¿cuál de estos registrarías como un Parámetro en lugar de una Métrica?

- A La tasa de aprendizaje usada para el entrenamiento ✓
- B La precisión del modelo en el conjunto de prueba
- C Una imagen de la matriz de confusión
- D El archivo del modelo entrenado

Los parámetros son entradas que fijas antes de empezar el entrenamiento; la tasa de aprendizaje es exactamente eso.

CUESTIONARIO · MLFLOW

PREGUNTA 2 DE 10

¿Cuál es la relación correcta entre un Experimento y una Ejecución (Run) en MLflow?

- A

Una Ejecución puede pertenecer a varios Experimentos a la vez
- B

Un Experimento agrupa varias Ejecuciones del mismo proyecto ✓
- C

Una Ejecución y un Experimento son términos intercambiables
- D

Los Experimentos se crean solo después de que terminan todas las Ejecuciones

Un Experimento es la carpeta; cada entrenamiento que registras dentro de ella es una Ejecución.

CUESTIONARIO · MLFLOW

PREGUNTA 3 DE 10

¿Qué función de MLflow se usa para guardar un modelo entrenado como una entidad reutilizable y versionada en el Model Registry?

A `mlflow.log_metric()`

B `mlflow.log_artifact()`

C `mlflow.register_model()` (o `log_model(..., registered_model_name=...)`)



D `mlflow.set_experiment()`

`register_model()` (o `log_model` con `registered_model_name`) es lo que realmente crea una entrada versionada en el Model Registry.

CUESTIONARIO · MLFLOW

PREGUNTA 4 DE 10

¿Por qué es útil registrar la misma métrica (por ejemplo, F1-score) en varias Ejecuciones con distintos hiperparámetros?

- A No es útil: una sola Ejecución siempre es suficiente
- B Reduce el tiempo de entrenamiento del modelo
- C MLflow requiere al menos 3 Ejecuciones por Experimento para funcionar
- D Permite comparar configuraciones de forma objetiva en lugar de confiar en la memoria ✓

Registrar la misma métrica entre configuraciones es lo que convierte el ajuste de hiperparámetros en una comparación en lugar de una adivinanza.

CUESTIONARIO · MLFLOW

PREGUNTA 5 DE 10

¿Cuál es la diferencia principal entre lo que hace Scikit-learn y lo que hace una herramienta de seguimiento de experimentos como MLflow?

A Scikit-learn realiza el entrenamiento/predicción real; MLflow registra lo que ocurrió durante ese proceso ✓

B Scikit-learn registra metadatos; MLflow entrena el modelo

C Hacen lo mismo, solo con sintaxis diferente

D MLflow elimina por completo la necesidad de una librería de machine learning

Scikit-learn hace el trabajo real de modelado; MLflow solo registra lo que ocurrió para que puedas encontrarlo después.

Al tratar valores atípicos con el método del RIC (rango intercuartílico), «acotar» (winsorizar) un valor significa:

A Eliminar la fila que lo contiene

C Reemplazarlo por la media de la columna

B Reemplazarlo por el límite más cercano del rango aceptable, en lugar de eliminar la fila ✓

D Ignorarlo durante el entrenamiento pero conservarlo para la evaluación

Acotar recorta el valor hasta el límite aceptable más cercano en lugar de descartar la fila.

CUESTIONARIO · PREPROCESAMIENTO Y MÉTODOS DE ENSAMBLE

PREGUNTA 7 DE 10

¿Por qué podría ayudar a un clasificador crear una razón (ratio) entre dos variables numéricas correlacionadas, en lugar de usarlas por separado?

- A Siempre mejora la precisión, sin importar el modelo
- B Reduce el tamaño del conjunto de datos
- C Puede capturar una relación entre las dos variables que es más relevante para el objetivo que cualquiera de los valores originales por separado ✓
- D Elimina la necesidad de una división entrenamiento/prueba

Una razón puede codificar la relación entre dos variables de una forma que ninguna de las variables originales captura por sí sola.

CUESTIONARIO · PREPROCESAMIENTO Y MÉTODOS DE ENSAMBLE

PREGUNTA 8 DE 10

¿Por qué es riesgoso reutilizar un mismo objeto ColumnTransformer/preprocesador ya ajustado en dos pipelines de modelos diferentes?

- A

No es riesgoso; es el enfoque recomendado
- B

Provoca una fuga de memoria que bloquea el kernel
- C

Los objetos ColumnTransformer solo pueden usarse una vez, y deben eliminarse después
- D

Ajustarlo de nuevo dentro del segundo pipeline puede cambiar silenciosamente su estado, afectando también al primer pipeline; usa clone() para evitarlo

✓

Ajustar un transformador compartido dentro de un segundo pipeline puede modificarlo silenciosamente; clone() mantiene a ambos independientes.

CUESTIONARIO · PREPROCESAMIENTO Y MÉTODOS DE ENSAMBLE

PREGUNTA 9 DE 10

¿Qué hace `handle_unknown='ignore'` cuando se pasa a un `OneHotEncoder`?

- A Evita un error cuando el codificador ve, al predecir, una categoría que nunca vio durante el entrenamiento ✓
- B Ignora los valores faltantes en el conjunto de entrenamiento
- C Omite la codificación de columnas con demasiados valores únicos
- D Desactiva la codificación one-hot y usa en su lugar codificación por etiquetas (label encoding)

Le indica al codificador que rellene con ceros una categoría no vista al momento de inferir, en lugar de lanzar un error.

Conceptualmente, ¿en qué se diferencia el Boosting (p. ej. XGBoost) del Bagging (p. ej. Random Forest)?

- A

El Boosting entrena árboles de forma independiente y en paralelo; el Bagging los entrena secuencialmente
- B

El Boosting entrena árboles secuencialmente, cada uno corrigiendo los errores de los anteriores; el Bagging entrena árboles de forma independiente sobre muestras bootstrap
- C

El Boosting solo admite tareas de regresión
- D

No hay una diferencia real entre los dos enfoques

El Boosting corrige errores secuencialmente, árbol tras árbol; el Bagging promedia árboles independientes entrenados en paralelo.

¿Qué es MLOps?

MLOps aplica la disciplina de DevOps —automatización, pruebas, versionado, monitoreo— a los desafíos particulares del machine learning: datos que cambian, modelos que se degradan y experimentos que deben ser reproducibles.

FIG. 01

DevOps

Integración continua, entrega continua, infraestructura como código y pruebas automatizadas.

FIG. 02

Ingeniería de Datos

Pipelines de datos, controles de calidad, versionado y gobernanza para los datos que alimentan cada modelo.

FIG. 03

Machine Learning

Experimentación, entrenamiento, evaluación y la naturaleza estadística del comportamiento del modelo.

MLOps vs. DevOps: Qué Cambia

MLOps surgió de DevOps, pero el machine learning introduce modos de fallo que la ingeniería de software tradicional no tiene.

Principios Compartidos

- Automatización de procesos
- Integración y despliegue continuos
- Colaboración y comunicación
- Escalabilidad y confiabilidad
- Monitoreo y ciclos de retroalimentación

Exclusivo de MLOps

Reproducibilidad

El mismo código y los mismos datos aún pueden dar resultados distintos: versiona datos, semillas, hiperparámetros y entorno.

Escalar Entrenamiento e Inferencia

El entrenamiento necesita hardware especializado (GPUs); el servicio debe ser rápido y barato para que valga la pena.

Drift del Modelo

La precisión se degrada cuando los datos reales se alejan de aquello con lo que se entrenó el modelo.

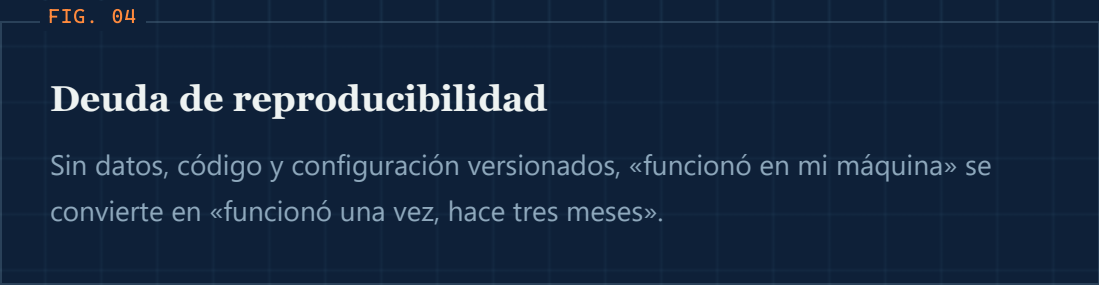
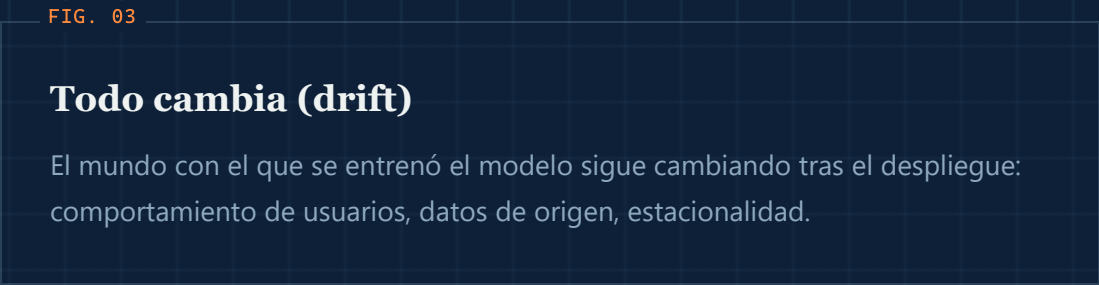
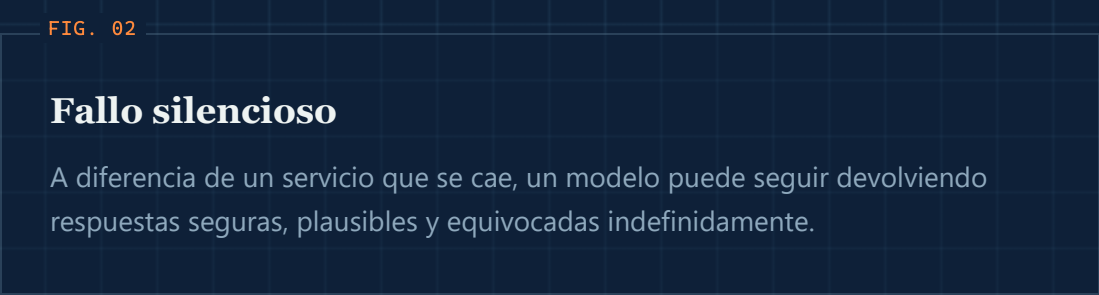
Composición del Equipo

Investigadores e ingenieros de producción tienen habilidades y ritmos distintos; deben aprender a trabajar juntos.

01 · FUNDAMENTOS


Por Qué Importa

Un notebook que produce una buena métrica no es un producto. La mayoría de las iniciativas de ML se estancan entre el prototipo y la producción, no porque el modelo esté mal, sino porque nada a su alrededor está operacionalizado.



El Ciclo de Vida del ML Es un Bucle


A diferencia del software tradicional, el ciclo de vida nunca termina realmente en el «despliegue». La retroalimentación de producción reconfigura continuamente la siguiente iteración.



↪ El reentrenamiento retroalimenta a Recolectar y Preparar

Versiona Todo

Si no puedes reconstruir exactamente qué produjo un modelo, no puedes depurarlo, auditarlo ni confiar en él. Cuatro cosas necesitan un historial de versiones.



Versionado de Datos y Linaje

La revisión de código responde «qué cambió y por qué». Los datos necesitan la misma respuesta: qué instantánea, transformada cómo, por qué proceso.

FIG. 01

Versiona como el código

Herramientas como DVC, LakeFS o Delta Lake permiten etiquetar, comparar y revertir conjuntos de datos igual que Git maneja los archivos fuente.

FIG. 02

Rastrea el linaje

Registra qué fuentes crudas, transformaciones y procesos produjeron cada tabla o variable derivada.

FIG. 03

Depura hacia atrás

Cuando un modelo se comporta mal, el linaje permite rastrear hacia atrás hasta el cambio exacto que lo causó.

FIG. 04

Habilita auditorías

Las industrias reguladas necesitan probar exactamente qué datos entrenaron un modelo en producción, meses después.

02 · REPRODUCIBILIDAD

DVC en la Práctica

Versiona conjuntos de datos y pipelines junto con Git: reproducibles por diseño.

TERMINAL

```
# versiona un conjunto de datos
dvc add data/train.csv
git add data/train.csv.dvc
git commit -m "Add training data v1"

# ejecuta el pipeline completo
dvc repro
```

DVC.YAML – DEFINICIÓN DEL PIPELINE

```
stages:
  preprocess:
    cmd: python src/data/preprocessing.py
    deps:
      - src/data/preprocessing.py
      - data/raw/transactions.csv
    outs:
      - data/processed/clean.csv
  train:
    cmd: python src/models/train.py
    deps:
      - src/models/train.py
      - data/processed/clean.csv
    metrics:
      - metrics.json
```

Cada versión del conjunto de datos está ligada a un commit de Git: al hacer checkout de cualquier commit, `dvc checkout` restaura exactamente los datos que lo produjeron.

Feature Stores

El error de producción más común en ML: variables (features) calculadas de forma distinta en entrenamiento que en servicio, el «training/serving skew».

FIG. 01

Almacén offline

Variables históricas y correctas en el momento exacto, usadas para construir los conjuntos de entrenamiento.

FIG. 02

Almacén online

Consultas clave-valor de baja latencia que sirven las mismas definiciones de variables en el momento de la inferencia.

Por qué importa

Un feature store define la lógica de cada variable una sola vez y la reutiliza en ambos caminos, eliminando toda una clase de errores silenciosos en producción.

Registra Cada Experimento

Si un resultado no se registra, no existió. El seguimiento de experimentos convierte ejecuciones improvisadas de notebooks en un historial buscable y comparable.

FIG. 01

Parámetros

Hiperparámetros, conjuntos de variables, semillas aleatorias: la receta de cada ejecución.

FIG. 02

Métricas

Curvas de pérdida, precisión, métricas de negocio: registradas paso a paso, no solo el número final.

FIG. 03

Artefactos

Pesos del modelo, gráficos e informes de evaluación adjuntos a la ejecución que los produjo.

Herramientas como MLflow o Weights & Biases existen principalmente para resolver la pregunta «¿cuál fue esa ejecución?».

03 · EXPERIMENTACIÓN

MLflow en Acción: Registra Todo

Una función de entrenamiento basada en configuración registra parámetros, métricas y el propio modelo en cada ejecución.

```
def train_model(config_path):  
    config = yaml.safe_load(open(config_path))  
    mlflow.set_experiment(config['experiment_name'])  
  
    with mlflow.start_run(run_name=config['run_name']):  
        mlflow.log_params(config['model_params'])  
  
        X_train, y_train = load_data(config['data_path'])  
        model = RandomForestClassifier(**config['model_params'])  
        model.fit(X_train, y_train)  
  
        mlflow.log_metric("accuracy",  
                          accuracy_score(y_val, model.predict(X_val)))  
        mlflow.sklearn.log_model(model, "model")
```

Compara experimentos visualmente en la interfaz de MLflow

Reproduce cualquier ejecución a partir de sus parámetros registrados y la versión del código

Despliega modelos directamente desde el registro

Entornos Reproducibles

«Funciona en mi máquina» no es aceptable para un trabajo de entrenamiento que debe ejecutarse de forma idéntica hoy, el próximo mes y en la laptop de un compañero.

FIG. 01

Contenedores

Las imágenes de Docker fijan el sistema operativo, los drivers y las librerías del sistema alrededor del código de entrenamiento/servicio.

FIG. 02

Dependencias fijadas

Versiones exactas y con hash de cada paquete, no rangos abiertos, para que una reconstrucción resuelva siempre igual.

FIG. 03

Infraestructura como código

Clústeres, GPUs y redes definidos en plantillas versionadas, no configurados a mano con clics.

03 · EXPERIMENTACIÓN

Cómo formatear su proyecto listo para Producción

Deja de usar notebooks planos, Un proyecto listo para producción separa responsabilidades: datos, código fuente, configuración y pruebas, cada uno con su propio lugar.

data/

conjuntos de datos crudos, procesados y con variables ya construidas

src/

código de datos, variables, modelos y evaluación

configs/

hiperparámetros y configuración del pipeline como código

tests/

validación automatizada de código y datos

notebooks/

solo para exploración, nunca lógica de producción

dvc.yaml

definición reproducible del pipeline

```
ml-project/
├── data/
│   ├── raw/
│   ├── processed/
│   └── features/
├── notebooks/
├── src/
│   ├── data/
│   ├── features/
│   ├── models/
│   └── evaluation/
├── configs/
├── tests/
├── mlruns/
├── dvc.yaml
└── requirements.txt
```

04 · AUTOMATIZACIÓN

CI para Machine Learning

Cada merge debería disparar algo más que un lint: validez de datos, pruebas rápidas de entrenamiento y controles de calidad del modelo antes de publicar nada.

```
name: ML Pipeline
on:
  push: { branches: [main] }

jobs:
  test:
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v3
      - uses: actions/setup-python@v4
      - run: pip install -r requirements.txt
      - run: pytest tests/

  train:
    needs: test
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v3
      - run: dvc pull
      - run: python src/models/train.py
      - run: python src/evaluation/metrics.py
```

test

Instala las dependencias y ejecuta la batería de pruebas antes de entrenar nada.

train

Solo se ejecuta si las pruebas pasan: descarga los datos versionados con DVC, entrena y evalúa.

Esta compuerta evita que un modelo defectuoso llegue alguna vez a producción.

Estrategias de Despliegue

Un modelo nuevo es una hipótesis, no una certeza. Desplégalo como cualquier cambio riesgoso: de forma gradual y con una salida de emergencia.

FIG. 01

Sombra (Shadow)

El modelo nuevo corre junto a producción, evaluando tráfico real en silencio para comparar, sin impacto en los usuarios.

FIG. 02

Canario (Canary)

Una pequeña porción del tráfico se enruta al modelo nuevo; se amplía solo si las métricas se sostienen.

FIG. 03

Azul/Verde (Blue/Green)

Dos entornos completos; el tráfico se cambia al instante, con reversión inmediata si es necesario.

Registro de Modelos y Gobernanza

Un catálogo central y versionado de modelos, con transiciones de etapa que requieren aprobación antes de llegar a producción.




FIG. 01

Fichas de modelo


El uso previsto, las limitaciones conocidas, un resumen de los datos de entrenamiento y los resultados de evaluación viajan junto con el modelo.

FIG. 02

Flujo de aprobación

El paso a producción requiere una autorización formal, no un push directo desde un notebook.

Arquitectura de un Sistema de ML en Producción



Los feature stores evitan el skew · El registro de modelos aporta control de versiones y ciclo de vida staging/producción · FastAPI sirve las predicciones · El monitoreo detecta drift y fallos

El Panorama de Herramientas de MLOps

Más allá de MLflow y DVC: un ecosistema más amplio cubre cada etapa del ciclo de vida del ML.



Fuente: InfluxData, «MLOps: A Comprehensive Guide to Machine Learning Operations»

Probar un Sistema de ML

Las pruebas unitarias solas no detectan un modelo que está estadísticamente equivocado. Los sistemas de ML necesitan su propia pirámide de pruebas.

FIG. 01

Pruebas de datos

Verificación de esquema, rangos, nulos y distribución en cada lote entrante.

FIG. 02

Pruebas unitarias

Transformaciones de variables y código del pipeline, probados como cualquier otro software.

FIG. 03

Pruebas de comportamiento

Verificaciones de invariancia y expectativas direccionales: p. ej., cambiar un campo no relacionado no debería alterar la predicción.

FIG. 04

Pruebas de integración

El pipeline completo de extremo a extremo, incluyendo latencia de servicio y verificación de contratos.

Entrenamiento Continuo

Un modelo entrenado una vez y nunca revisado eventualmente quedará obsoleto. El reentrenamiento debería ser un pipeline, no una emergencia.

FIG. 01

Programado

Reentrena con una cadencia fija que coincida con la rapidez con la que realmente cambian los datos subyacentes.

FIG. 02

Disparado por drift

Inicia el reentrenamiento automáticamente cuando los datos de entrada o las predicciones se desvían más allá de un umbral.

FIG. 03

Disparado por degradación

Se activa cuando las métricas de desempeño en vivo caen por debajo de un mínimo acordado.

Buenas Prácticas

Cinco hábitos que distinguen a los equipos que llevan ML a producción de forma confiable.

1

Trata la Configuración como Código

Nunca fijas los hiperparámetros en el código; usa archivos de configuración YAML versionados.

2

Automatiza los Controles de Calidad de Datos

Valida cada lote con herramientas como Great Expectations antes de entrenar.

3

Implementa Monitoreo de Modelos

Detecta el drift de datos automáticamente y dispara el reentrenamiento (p. ej. con Evidently).

4

Versiona Todo

Código en Git, datos en DVC, modelos en el Registry de MLflow, infraestructura en Terraform.

5

Despliegues en Modo Sombra

Ejecuta los modelos candidatos junto a producción y compáralos antes de promoverlos.

Errores Comunes y Cómo Evitarlos

Cuatro errores que hunden en silencio los proyectos de ML, y cómo corregir cada uno.

FIG. 01

Training/Serving Skew

PROBLEMA: Las variables se calculan de forma distinta en entrenamiento y en producción.

SOLUCIÓN: Usa un feature store o código de ingeniería de variables compartido para ambos.

FIG. 03

Ignorar la Degradación del Modelo

PROBLEMA: La precisión se degrada silenciosamente a medida que el mundo cambia.

SOLUCIÓN: Programa reentrenamientos regulares y monitorea el desempeño de forma continua.

FIG. 02

Fuga de Datos en la Validación Cruzada

PROBLEMA: Mezclar los datos antes de dividirlos deja que información futura se filtre al entrenamiento.

SOLUCIÓN: Usa divisiones basadas en el tiempo para datos temporales.

FIG. 04

Sobre-ingeniería Prematura

PROBLEMA: Construir clústeres de Kubernetes antes de validar el valor del modelo.

SOLUCIÓN: Sigue el principio gatear → caminar → correr: empieza simple y añade complejidad cuando el valor esté probado.

06 · ERRORES COMUNES

Cómo Corregir un Error Común: Divisiones Basadas en el Tiempo

Mezclar aleatoriamente es la causa más común de fuga de datos en problemas de series temporales.

INCORRECTO

```
# Incorrecto: los datos futuros se filtran al entrenamiento
X_train, X_test = train_test_split(
    X, test_size=0.2, shuffle=True)
```

CORRECTO

```
# Correcto: dividir estrictamente por tiempo
split_date = df['date'].quantile(0.8)
train = df[df['date'] < split_date]
test = df[df['date'] ≥ split_date]
```

Monitoreo y Observabilidad

Un modelo desplegado necesita tres capas de visibilidad: la salud del sistema por sí sola no es suficiente.

FIG. 01

Operacional

Latencia, throughput, tasa de errores, uso de recursos: las mismas señales que cualquier servicio.

FIG. 02

Drift de datos y predicciones

¿Las entradas y salidas siguen siendo estadísticamente similares a aquello con lo que se entrenó el modelo?

FIG. 03

Impacto de negocio

¿El modelo sigue moviendo la métrica para la que fue construido: conversiones, fraude detectado, cancelaciones evitadas?

Drift de Datos y de Concepto

El mundo cambia. Dos modos de fallo relacionados pero distintos explican la mayor parte de la degradación de modelos tras el despliegue.

FIG. 01

Drift de datos

La distribución de las variables entrantes se aleja de los datos de entrenamiento: un nuevo segmento de usuarios, un cambio estacional, un cambio de esquema en el origen.

FIG. 02

Drift de concepto

La relación entre las variables y el objetivo cambia: lo que antes predecía el resultado ya no lo hace.

Las pruebas estadísticas sobre las distribuciones de variables y predicciones detectan el drift antes de que aparezca como una métrica de negocio en llamas.

Respuesta a Incidentes y Rollback

Trata un despliegue de modelo fallido como cualquier incidente de producción: con un plan decidido antes de que ocurra, no durante.

FIG. 01

Rollback instantáneo

El registro siempre mantiene la última versión buena conocida a un solo comando de volver a servir.

FIG. 02

Interruptor de emergencia

Una forma de volver a una respuesta simple basada en reglas o al modelo anterior si el nuevo se comporta mal.

FIG. 03

Postmortems

Revisión sin culpas de qué se desvió, qué no detectó el monitoreo y qué prueba lo habría atrapado.

Seguridad, Privacidad y Cumplimiento

Los modelos se entrenan con datos sensibles y toman decisiones con consecuencias reales: ambas cosas necesitan controles explícitos, no suposiciones.

FIG. 01

Control de acceso
Quién puede leer los datos de entrenamiento, descargar un artefacto de modelo o promoverlo a producción, con alcance definido y auditado.

FIG. 02

Manejo de datos personales (PII)
Minimiza, enmascara o anonimiza los campos sensibles en cualquier punto donde entren al pipeline.

FIG. 03


Rastros de auditoría
Cada ejecución de entrenamiento y despliegue vinculado a quién, qué y cuándo.

FIG. 04

Preparación regulatoria
Las fichas de modelo y el linaje hacen que «explica esta decisión» sea algo responsable, no una excavación arqueológica.

Equipo y Colaboración

MLOps es tanto una práctica organizacional como técnica: falla cuando los equipos se lanzan el trabajo por encima del muro.



La propiedad compartida de los resultados en producción, y no una simple entrega en el registro de modelos, es lo que realmente mantiene sanos a los sistemas.

Caso de Estudio: Sistema de Recomendaciones en Producción

Contexto

- Plataforma de comercio electrónico
- 500 mil usuarios mensuales
- Necesitaba recomendaciones de productos basadas en ML
- Caídas frecuentes y cero reproducibilidad

Desafíos

Sin versionado	Más de 20 archivos pickle dispersos en una unidad compartida
Experimentos lentos	8 horas de tiempo de entrenamiento
Sin monitoreo	No se podía detectar la degradación del modelo
Despliegues manuales	Ciclos de lanzamiento de 6 horas

Caso de Estudio: La Solución en Tres Fases

Tres fases convirtieron un proceso frágil y manual en un pipeline confiable.

1

Infraestructura
MLflow en EC2 + PostgreSQL, DVC + S3, registro y paneles

2

Entrenamiento Distribuido
Modelo Spark ALS: de 8 h a 45 min


3

Servicio del Modelo
Endpoint de FastAPI que carga desde el registro de MLflow

10 · CASO DE ESTUDIO

Caso de Estudio: Resultados

Antes → después de adoptar MLOps.




LOGROS TÉCNICOS

- ✓ Los 47 experimentos quedaron registrados en MLflow
- ✓ El versionado de datos permitió revertir pruebas A/B
- ✓ Reentrenamiento automatizado cada domingo a las 2 AM
- ✓ Paneles de desempeño del modelo en Grafana

Un Modelo de Madurez de MLOps

La madurez es un gradiente, no un interruptor. La mayoría de las organizaciones avanza por estas etapas una capacidad a la vez.



Implementar MLOps: Una Hoja de Ruta

Un camino general que siguen las organizaciones para establecer una práctica de MLOps.

1	Establece tu punto de partida y tus objetivos Mide tu tiempo de despliegue y precisión actuales; define metas de mejora concretas.
2	Forma el equipo de MLOps Combina ciencia de datos, ingeniería, operaciones y conocimiento del negocio.
3	Define la gobernanza de datos Establece estándares de recolección, almacenamiento, versionado, calidad y cumplimiento.
4	Elige herramientas y plataformas Evalúa construir vs. comprar, la experiencia del equipo y el soporte de la comunidad.
5	Automatiza el pipeline de despliegue Empieza con CI/CD para probar, rastrear y promover modelos.
6	Itera y mejora MLOps es continuo: revisa los objetivos y sube el estándar con el tiempo.

CIERRE

Conclusiones Clave

FIG. 01

Versiona todo

Código, datos, modelos y configuración, todo reconstruible.

FIG. 02

Automatiza el pipeline

Desde la validación de datos hasta el despliegue, no solo el entrenamiento.

FIG. 03

Monitorea en producción

El drift y la degradación son la norma; vigílalos de forma continua.

FIG. 04

Comparte la responsabilidad

MLOps funciona como una práctica de equipo, no como una entrega.

Gracias.

PRÓXIMOS PASOS 1. Configura MLflow en tu máquina · 2. Versiona tu primer conjunto de datos con DVC · 3. Escribe una prueba automatizada · 4. Despliega a staging y monitorea durante una semana